

FORMULARIO STATISTICA

Funzione

Definire una funzione **y<-function(x)(3*x+7)**

Grafico

plot(y) se voglio dire gli estremi **plot(y, -10, 10)**

Cancellare lo script

rm(list=ls())

Costruzione variabile nominale

Costruzione vettore nominale sesso di bambini (esempio)

sesso<-("M", "F", "M", "M", "M", "F")

Frequenza relativa

La frequenza di un valore divisa per il numero totale di frequenze

str(x) —> per vedere la stringa “x” ovvero tutti gli elementi

Tabella delle frequenze, frequenze relative o proporzionali

#tabella delle frequenze

freq_peso<-table(peso)

#tabella delle frequenze relative o proporzionali chiamata “rel peso”

rel_peso<- prop.table(freq_peso)

Approssimare alla seconda decimale

appr_peso<- round(rel_peso, digits=2)

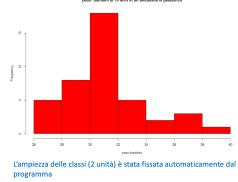
Frequenze percentuali

#frequenze percentuali

freq_percent<- round(rel_peso*100, digits=2)

Istogrammi

hist(peso, col="green", main="freq assolute peso", xlab= "peso bambini", ylab= "frequenze assolute")

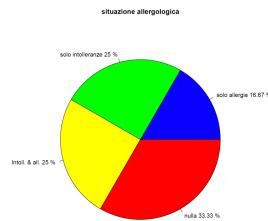


Altri grafici

A) Diagrammi a torta

tabella<-table(allergie) tabella sulla console

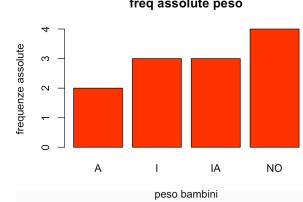
pie(tabella)



B) Diagramma a barre

#diagramma a barre

barplot(tabella)



Calcolo della media

Media campionaria = $(x_1 + x_2 + \dots + x_n)/n$

peso_medio <- mean(peso)

Media ponderata = $(x_1 * f_1 + x_2 * f_2 + \dots + x_n * f_n)/n$

wa <- sum(x*f)/n

Mediana

median(peso)

Summery

Il comando “**summery()**” fornisce:

- gli estremi del campione;
 - la mediana e i quartili;
 - la media campionaria.
-

Varianza

Serve per determinare la dispersione dei dati rispetto alla media campionaria

$$s^2 = (x_k - \text{media}) * f / (n - 1)$$

var()

Deviazione standard

a) `s2<-var() -> sqrt(s2) -> Var(x)`

b) **sd ()**

Coefficiente di variazione

Serve per confrontare la deviazione standard e il valore assoluto della media campionaria

coeff_di_variazione <- sd() / mean()

Data frame

Se voglio leggere o vedere solo una colonna della tabella (ad esempio)

#leggere una variabile all'interno di un data set

inquinante\$Lago.3 -> str(inquinante\$Lago.3)

Percentile

è una misura usata in statistica per indicare il minimo valore sotto al quale ricade una data percentuale degli altri elementi sotto osservazione.

Es calcola il 10 percentile

perc10<-quantile (x, 0.10) (0.10 perchè è 10%)

Tra i percentuali assumono particolare importanza i QUARTILI sono quei valori/modalità che ripartiscono la popolazione in quattro parti di uguale.

Ordinare il campione

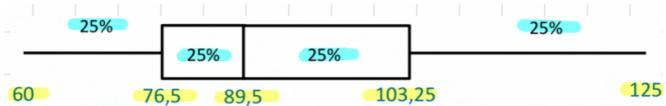
sort()

Boxplot

È un **metodo grafico** per rappresentare la suddivisione in **quartili** dei dati.

Si ottiene tracciando una linea che va dal più piccolo al più grande dei dati e due suddivisioni (box) che rappresentano i quartili.

Ogni box contiene il 25% dei dati:

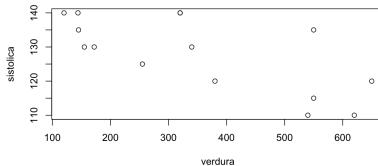


boxplot (x, horizontal = TRUE, col="red", main="titolo")

Scatterplot

è un tipo di grafico in cui due variabili di un set di dati sono riportate su uno spazio cartesiano.

plot (x,y)



- se c'è qualche correlazione → curva;
- se c'è correlazione lineare → retta.

Covarianza

Per verificare se fra due variabili statistiche c'è qualche legame lineare.

$$\text{cov}(x, y) = (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$$

cov (x,y)

La covarianza può essere:

POSITIVA

x e y variano nella **STESMA DIREZIONE**

al crescere di x cresce y
al diminuire di x diminuisce y
e viceversa

NEGATIVA

x e y variano in **DIREZIONI OPPOSITE**

al crescere di x
 y tende a diminuire

NULA

nessuna
tendenza

$\text{cov}(x, y) = 0$
→ **NESSUNA CORRELAZIONE**

Coefficiente di correlazione di Pearson

Serve per calcolare il grado di intensità della correlazione lineare di una coppia i campioni

cor (x,y) —> “r”

Valutazione sull'intensità di correlazione

A) valori positivi di r

$0 < r < 0.25$	debole o nessuna
$0.25 < r < 0.75$	moderata
$0.75 < r < 1$	forte

B) valori negativi di r

$-0.25 < r < 0$	debole o nessuna
$-0.75 < r < -0.25$	moderata
$-1 < r < -0.75$	forte

Nel caso in cui vi sia una significativa correlazione lineare (FORTE) si può costruire una retta chiamata retta di regressione

Retta di regressione

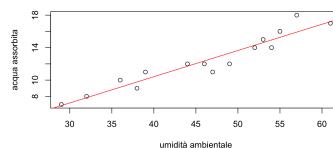
$$m = \text{pendenza} \rightarrow \beta_1 = r_{xy} \frac{s_y}{s_x}; \quad q = \text{intercetta} \rightarrow \beta_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Con R : **lm(x~y)**

Sovrapposizione tra retta di regressione e i dati reali del campione

plot(x~y)

abline(retta di regressione)



Probabilità:

Spazio campionario

Simbolo: Ω

Significato: insieme di tutti i possibili esiti di un esperimento

Evento

Simbolo: E

Significato: sottoinsieme dello spazio campionario $E \subset \Omega$

Operazioni tra insiemi

A) UNIONE $A \cup B = \{x \in \Omega; x \in A \text{ oppure } x \in B\}$

B) INTERSEZIONE $A \cap B = \{x \in \Omega; x \in A \text{ e } x \in B\}$

C) COMPLEMENTARE $A^c = \{x \in \Omega; x \notin A\}$

Leggi di de Morgan: $(A \cup B)^c = A^c \cap B^c$ e $(A \cap B)^c = A^c \cup B^c$

Insieme delle parti

Diciamo "*insieme delle parti*" una famiglia A di sottoinsiemi di Ω che soddisfi i seguenti criteri:

1. A non è vuoto $\rightarrow A \neq \emptyset$
2. Se $E \in A$, allora $\rightarrow E^c \in A$
3. Se $E_1, E_2 \in A$ allora $\rightarrow E_1 \cup E_2 \in A$ (A è chiuso rispetto alle operazioni di unione, intersezione)

$P(\Omega)$ = famiglia di tutti i sottoinsiemi di Ω / insieme delle parti di Ω

Definizione di probabilità

Dati Ω spazio campionario e A sistema di eventi, diciamo *probabilità su Ω* un'applicazione $\rightarrow P : A \rightarrow R; E \rightarrow P(E)$

che soddisfa: 1. $0 < P(E) < 1$

2. $P(\Omega) = 1$

3. Se $A, B \in A, A \cap B = \emptyset$ allora $P(A \cup B) = P(A) + P(B)$

Regole del calcolo della probabilità

- A) Probabilità del complementare $P(A^c) = 1 - P(A)$
 - B) Evento impossibile $P(\emptyset) = 0$
 - C) Partizione dell'evento certo $P(B) = P(B \cap A) + P(B \cap A^c)$
 - D) Ordinamento $A \subset C \rightarrow P(A) \leq P(C)$
 - E) Unione di eventi non disgiunti $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
-

Eventi indipendenti

A e B sono indipendenti se il verificarsi di A **non influenza** la probabilità che si verifichi B e viceversa

$$P(A \cap B) = P(A)P(B)$$

Spazi di probabilità uniformi

Diciamo che (Ω, P) è uno **“spazio di probabilità uniforme”** se

1. Ω è finito;
2. $\forall \omega \in \Omega, P\{\omega\} = p$ indipendentemente dal valore di ω . (Ovvero se la probabilità è la stessa per ogni esito in Ω)

Usiamo la notazione $-|A| =$ tutti gli elementi dell'insieme A

$$-p = 1 / |\Omega|$$

Dunque $\forall A \in P(\Omega)$ abbiamo che $P(A) = (|A|)*p = |A| / |\Omega|$

Dunque in questo caso si può dire che **Probabilità = casi favorevoli/casi possibili**

Variabili aleatorie

Data una popolazione generica Ω , diciamo **variabile aleatoria su Ω** una variabile “X” che assume **casualmente** i suoi valori nella popolazione Ω .

Generalmente possiamo considerare l'evento $X = k$:

Considerata una variabile aleatoria X, ha senso calcolare $P(X=k)$

Variabile aleatoria **discreta**

È una variabile aleatoria che assume valori discreti $x=0,1,2,\dots,n$ e $y=x_1, x_2, x_3\dots$

Sempre in generale diciamo che $x_k \in \text{range di } X$ se $P(x=x_k) \neq 0$

Densità di probabilità o funzione di distribuzione o pdf (probability distribution function)

Funzione : fornisce la probabilità di ogni evento costruito a partire da X :

$$f_x(x) = P(X=x) \text{ oppure } p_k = P(X=k)$$

Regole :

1. $\forall k \quad 0 < p_k < 1$
 2. $p_k = P(X=k) = 0$ se $k \notin \text{range di } X$
 3. $\sum p_k = 1$
-

Valore atteso

In generale il valore atteso di una variabile casuale discreta (che assuma cioè solo un numero finito o una infinità numerabile di valori) è dato dalla somma dei possibili valori di tale variabile, ciascuno moltiplicato per la probabilità di essere assunto (ossia di verificarsi), cioè è la media ponderata dei possibili risultati.

Diciamo “valore atteso” di X (media, valor medio, speranza matematica, attesa) la quantità:

$$\mu = E[X] = \sum x_i * P(X=x_i)$$

Proprietà:

1. $E[cX] = cE[X]$
 2. $E[X + Y] = E[X] + E[Y]$
-

Varianza e deviazione standard di una v.a.

Rappresentano la dispersione dei possibili valori di X rispetto al valore atteso.

Data X, variabile aleatoria finita, diciamo “varianza di X” la quantità:

$$\sigma^2 = s^2 = Var(X) = \sum (x_i - \mu)^2 * P(X=x_i)$$

Diciamo “deviazione standard di X”:

$$\sigma = s = \sqrt{Var(X)}$$

Proprietà:

1. $Var(aX) = a^2 Var(X)$;
2. $Var(a + X) = Var(X)$ (invarianza per traslazione);
3. Se X,Y sono indipendenti allora $E[XY] = E[X] E[Y]$ e $Var(X+Y) = Var(X) + Var(Y)$.

Processi di Bernoulli - Distribuzione Binomiale

Prova Bernoulliana

Diciamo prova bernoulliana un esperimento che può avere solo due risultati

V successo	$P(V) = p$
F insuccesso	$P(F) = 1 - p$

N.B: p per convenzione indica sempre la probabilità di successo

Variabile aleatoria di Bernoulli

Diciamo v.a. di Bernoulli la v.a. :

$$X \sim B(p)$$

Essa può assumere due valori:

X = 1	Successo (V)	$P(X=1) = p(1) = p$
X = 0	Insuccesso (F)	$P(X=0) = p(0) = 1-p$

Valore atteso

Indica quante volte in media abbiamo successo

$$E[X] = p$$

Varianza

$$Var(X) = p(1 - p)$$

Processi di Bernoulli

È una sequenza (anche illimitata) di prove bernoulliane.

1. Prove indipendenti;
 2. Tutte con la stessa probabilità di successo $p \in (0,1)$.
- **Limitati** : sequenza di numero **fissato** n di prove bernoulliane ;
 - **Illimitati** : sequenza di numero **infinito** di prove bernoulliane .

Processi di Bernoulli limitati :

- X_0 : numero di successi ottenuti in n prove;
- X può assumere i valori: 0,1,2,..n ;
- X è detta variabile aleatoria binomiale di parametri n (numero di prove) e p (probabilità di successo in ogni prova)
- Si indica $X \sim B(n, p)$

Valore atteso e varianza di un processo bernoulliano limitato

Valore atteso : $E[X] = np$;

Varianza : $Var(X) = np(1 - p)$

FUNZIONI IN R :

Fattoriale

FUNZIONE: $n! = factorial(n)$

Coefficiente binomiale

Calcoliamo coefficienti binomiali

FUNZIONE:

A) Regola matematica: $n \text{ binomiale } k \rightarrow choose(n, k): k \leq n$

B) Funzione precostituita: $PP_7 <- dbinom(7, size=n, prob=p)$

Per calcolare ad esempio $P(x \leq 2) = P(x=0) + P(x=1) + P(x=2)$

usiamo la funzione $p <- sum(dbinom((0:2), size=n, prob=p))$

Setnames

Questa è una funzione comoda che imposta i nomi su un oggetto e restituisce l'oggetto. È molto utile alla fine della definizione di una funzione in cui si sta creando l'oggetto da restituire e si preferisce non memorizzarlo con un nome solo per poter assegnare i nomi.

In questo caso

Tabuliamo pdf:

`tab.pdf<-setNames(pdf,k)`

pdf = distribuzione e k = vettore range della variabile

Realizzazione di una variabile

Assumiamo di aver estratto concretamente un valore x dalla popolazione:

x è detto realizzazione della variabile aleatoria X

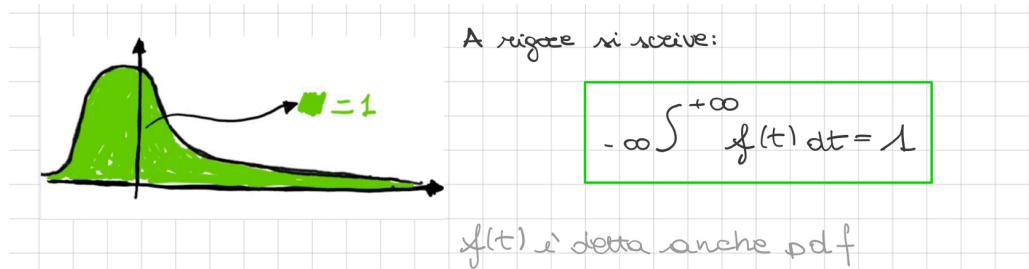
Esempio: scommettiamo sul lancio di due dati: scommettiamo sul 7 ma all'estrazione esce il numero 5 (realizzazione di X). Dato di fatto: abbiamo perso qualsiasi fossero le previsioni probabilistiche di X

Variabile aleatoria discreta

Assumono valori in un intervallo di numeri reali (es. $[0, \infty]$, $[0.4, 10]$ ecc)

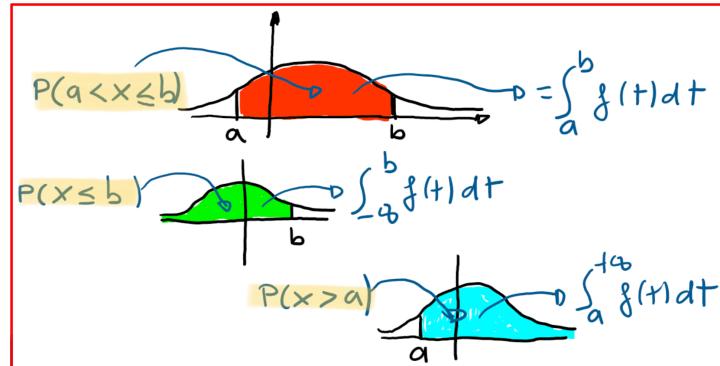
Funzione densità PDF

È una funzione $0 < f(t) < 1$ tale che l'area sottesa al suo grafico sia pari a 1:



Calcolo della probabilità

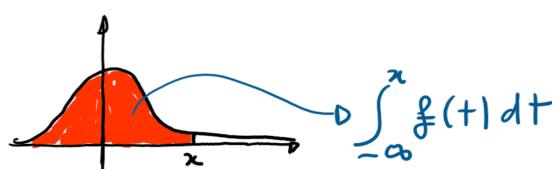
$\forall a, b \in \mathbb{R}, a < b$ la probabilità $P(a < X < b)$ è data dall'area sottesa al grafico tra l'intervallo $[a, b]$:



Funzione di ripartizione CDF (cumulative distribution function)

$$F(t) = P(X < t)$$

- ① F funzione non decrescente;
- ② $\lim_{x \rightarrow -\infty} F(x) = 0$;
- ③ $\lim_{x \rightarrow +\infty} F(x) = 1$.



Funzione di ripartizione e calcolo della probabilità

- A) Dato un intervallo $[a,b]$ $P(a < X < b) = F(b) - F(a)$
- B) La funzione di ripartizione ci permette di calcolare $P(a < X < b)$, dunque $F(x)$ descrive completamente la distribuzione della v.a. X.
- C) Calcolare gli estremi o non calcolarli non fa differenza

Valore attesa e varianza per una variabile continua

Valore atteso: $\mu = E[X] = \int_{-\infty}^{+\infty} t f(t) dt$

Intuitivamente può essere considerato come la media dei possibili valori di X pesati in modo continuo dalla densità $f(t)$.

Varianza: $\sigma^2 = Var(X) = E[(x-\mu)^2] = \int_{-\infty}^{+\infty} (t - \mu)^2 f(t) dt$

Distribuzione normale standard

$$Z \sim N(0,1)$$

$$E[Z] = 0 \quad \text{e} \quad Var(Z) = 1$$

$$\varphi(t) := \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$$

In R: $\varphi(x) = dnorm(x, mean=0, sd=1)$

Calcolo della probabilità per distribuzione Normale Standard

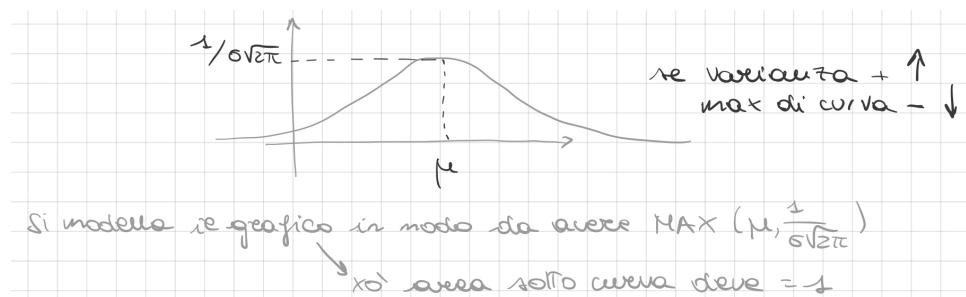
Utilizziamo R perchè non si può fare in altro modo.

Distribuzione normale di media μ e varianza σ^2

$$X \sim N(\mu, \sigma^2) \text{ definita da } X = \sigma Z + \mu$$

$$X \sim N(\mu, \sigma^2) \iff Z \sim N(0,1)$$

Curva della distribuzione normale:



Proprietà della distr. normale

Date:

- X v.a. normale di media μ_x e varianza σ_x^2 , $X \sim N(\mu_x, \sigma_x^2)$
- Y v.a. normale di media μ_y e varianza σ_y^2 , $Y \sim N(\mu_y, \sigma_y^2)$
- X e Y indipendenti

ALLORA: $X + Y \sim N(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2)$

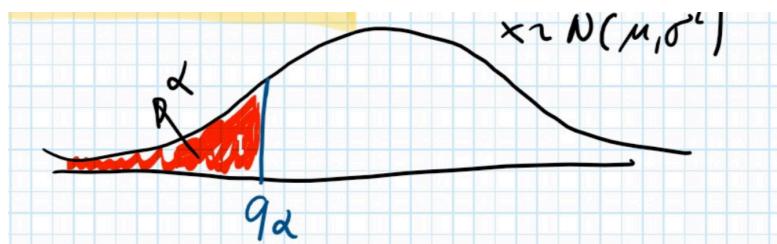
Attenzione! Le varianze di sommano, le deviazioni standard no!

Quantili della distr. normale standard

Considerata la v.a. normale standard $Z \sim N(0,1)$ e fissata una probabilità $0 < \alpha < 1$

Diciamo *quantile di ordine α* , il valore z_α tale che: $P(Z < z_\alpha) = \alpha$

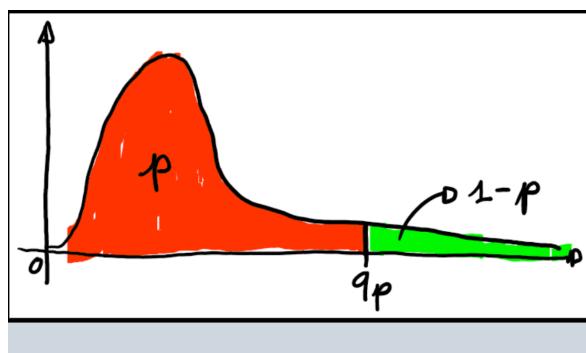
In R : `qnorm(alpha, mean=0, sd=1) = qnorm(α)`



Quantili in generale

Data una v.a. X di densità $f(t)$ e funzione $F(t) = P(X < t)$, fissata una probabilità $0 < p < 1$ diciamo *quantile di ordine p* :

il valore $q_p \in R$ tale che $P(X < q_p) = p$



Le proprietà dei quantili z_p della distribuzione normale standard sono basate sulla simmetria rispetto all'asse delle ordinate della funzione gaussiana.

Dunque non sono valide in generale per i quantili q_p una distribuzione qualsiasi

Tabella CODICI R per distribuzioni

Distribuzione	pdf (densità)	cdf (ripartizione)	quantili di ordine α
$X \sim \text{unif} [a,b]$	dunif (x, min=a, max=b)	punif ((x, min=a, max=b)	qunif ((x, min=a, max=b)
$X \sim N (\mu, \sigma^2)$	dnorm (x, mean=μ, sd=σ)	pnorm (x, mean=μ, sd=σ)	qnorm (x, mean=μ, sd=σ)
$X \sim B (n,p)$	dbinom (x, size=n, prob=p)	pbinom (x, size=n, prob=p)	qbinom (x, size=n, prob=p)

Per riassumere:

pdf (densità)	d “ <i>nome</i> ” = (x, parametri)
cdf (funzione di ripartizione)	p “ <i>nome</i> ” = (x, parametri)
Quantili di ordine α	Q “ <i>nome</i> ” = (x, parametri)

Statistica inferenziale

Vogliamo ottenere informazioni sull'**intera popolazione** a partire dai dati ottenuti attraverso il campionamento.

Procedimento

- 1) Fissiamo un campione aleatorio
- 2) Dallo studio teorico otteniamo informazioni sulla distribuzione di probabilità
- 3) Realizzazione:
 - estraiamo campione di dati;
 - Con strumenti teorici (B) effettuiamo stime su μ e σ

Campione aleatorio **indipendente identicamente distribuito**

Chiamiamo *campione aleatorio i.i.d.* una famiglia di variabili aleatorie che soddisfino:

1. Indipendenti
2. Stessa distribuzione (= pdf)
3. Stessa varianza ($= \sigma^2$)
4. Stesso valore atteso ($= E[X]$)

Valore atteso $E[X_{\text{media}}]$

$$E[X_{\text{media}}] = \mu$$

Non dipende da n (ampiezza)

Varianza $\text{Var}(X_{\text{media}})$

$$\sigma^2 / n$$

Dipende da n ($\uparrow n ; \downarrow \text{Var}$)

Se la popolazione è normale di media μ e varianza σ^2

$$X_{\text{media}} \sim N(\mu, \sigma^2 / n)$$

Teorema del limite centrale

Se:

- campione i.i.d.
- media μ
- varianza σ^2
- $n \geq 30$

Allora: Assumiamo che la popolazione abbia **distribuzione normale**:

$$\bar{X}_{\text{media}} \sim N(\mu, \sigma^2 / n)$$

Realizzazione di un campione aleatorio

Un campione casuale semplice estratto concretamente dalla popolazione

Su R comando **r+nome variabile(...)**

N (μ , σ^2)	rnorm (n, mean=mu, sd=sigma)
unif ([a,b])	runif (n, max=b, min=a)
B (n,p)	rbinom (n, size=N, prob=p)

Intervallo di confidenza per media nota con varianza non nota

- Estraiamo un campione casuale di ampiezza n
- Fissiamo un livello di fiducia/confidenza $CL=1 - \alpha$

$$cl < -0.99$$

$$\alpha = 1 - cl$$

$$\alpha$$

- Calcoliamo la media campionaria

$$\bar{x} = \text{mean}(x)$$

- Intervallo di confidenza per la media, al livello di fiducia $1 - \alpha$ è $\bar{x} - E, \bar{x} + E$

$$z_{\text{star}} = qnorm(1 - \alpha / 2)$$

$$E = z_{\text{star}} * \sigma / \sqrt{n}$$

$$IC = \bar{x} + z_{\text{star}} * \sigma / \sqrt{n}$$

Risposta: - l'intervallo di c. è [estremo sx, estremo dx]

- il livello medio di rumorosità è $\mu = \bar{x} \pm E$

Se la popolazione ha **media e varianza entrambe NON note?**

σ^2 non nota -> non utilizzabile per costruire intervallo di confidenza

Introduciamo quindi:

- **Varianza campionaria** $S^2 = 1/(n - 1) * \sum(x_j - \bar{x})^2$
- **Deviazione standard campionaria** $S = \sqrt{S^2}$

Esse sono chiamate “*variabili aleatorie statistiche*” -> servono per stimare μ e σ .

Si verifica che $\frac{\bar{x} - \mu}{(S / \sqrt{n})} = t_{n-1}$ = distribuzione t di student con n-1 gradi di libertà

Distribuzione t-di student $X \sim t_n$

Descritta da densità $f(t)$ con grafico molto simile alla normale standard (campana simmetrico rispetto ad origine) ma è più precisa della normale

$$E[X] = 0$$

$$\text{Var}(X) = \frac{n}{n-2} \rightarrow \text{sempre } \text{Var}(X) > 1$$

$$\text{In R: } f(t) = dt(t, df=n)$$

Quantili della t di student

$$t^* = qt(alpha, df=n)$$

Intervallo di confidenza per media nota con varianza non nota

- a) consideriamo un campione casuale di ampiezza n
- b) Calcoliamo media e varianza campionarie $\bar{x} <- \text{mean}(x)$ $s^2 <- \text{var}(x)$
- c) Intervallo di confidenza al livello di confidenza $CL = 1 - \alpha$

$$[\bar{x} - E, \bar{x} + E]$$

$$E <- t^* S / \sqrt{n}$$

$$t^* = qt(\alpha, df=n)$$

Intervallo di confidenza è dunque: $\mu = \bar{x} \pm E$

$$\mu \in [\text{estremo sx; estremo dx}]$$

Proporzione di successi in una popolazione bernoulliana

- Consideriamo la popolazione bernoulliana (successo/insuccesso) con probabilità di successo p in ogni prova (p ignota)
- Consideriamo un campione aleatorio i.i.d.
- Variabile aleatoria che conta il numero di successi del campione:

$$\hat{p} = (\text{numero di successi di campione di ampiezza } n) / n$$

SE $n*p \geq 5$ e $n*(1-p) \geq 5 \rightarrow \text{ALLORA } [\hat{p} - p] / \sqrt{p*(1-p)/n} \sim N$
 (Ha distribuzione normale standard)

Intervalli di confidenza per proporzione di successi in pop. Bernoulliana

- popolazione Bernoulliana
- Fissiamo livello di confidenza $CL = 1-\alpha$
- Estraiamo campione casuale
- Calcoliamo \hat{p}
- Verifichiamo che $n*p \geq 5$ e $n*(1-p) \geq 5$
- Calcoliamo errore statistico $E = z_{(1-\alpha/2)} * [\hat{p}(1-p) / n]$

$$z_{(1-\alpha/2)} = qnorm(1-\alpha/2)$$

Intervallo di confidenza è dunque: $[\hat{p} - E ; \hat{p} + E]$

$$p = \hat{p} \pm E$$

Come si stima la varianza di una popolazione?

Stima della varianza

- Consideriamo una popolazione con varianza NON nota

SE consideriamo la varianza campionaria $S^2 \rightarrow$ ALLORA si verifica che $E[S^2] = \sigma^2$

S^2 è un buon stimatore di σ^2

Si verifica inoltre che la variabile aleatoria $(n-1) * S^2 / \sigma^2$ ha distribuzione "chi quadro con $n-1$ gradi di libertà"

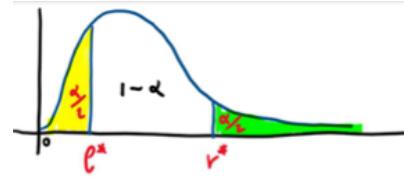
Distribuzione chi-quadro con $n-1$ gradi di libertà (χ)

In R: **dchisq(x, df=n)**

Quantili della chi-quadro

Sinistro : **Istar <- qchisq(alpha/2, df=n-1)**

Destro : **rstar <- qchisq(1-alpha/2, df=n-1)**



Intervalli di confidenza per la varianza

- Popolazione normale con varianza NON nota
- Fissiamo il livello di confidenza $CL = 1 - \alpha$
- Estraiamo campione casuale
- Media e varianza campionarie \bar{x} e S^2
- Calcoliamo i quantili l_{star} e r_{star}

Intervallo di confidenza è dunque:
$$\left(\frac{(n-1)s^2}{r^*} ; \frac{(n-1)s^2}{l^*} \right)$$

Test di ipotesi

Procedura per assumere con un certo livello di significatività statistica se l'affermazione H_0 debba essere rifiutata o non rifiutata.

A) Ipotesi nulla H_0

Afferma che un parametro della popolazione è uguale ad un valore teorico fissato.

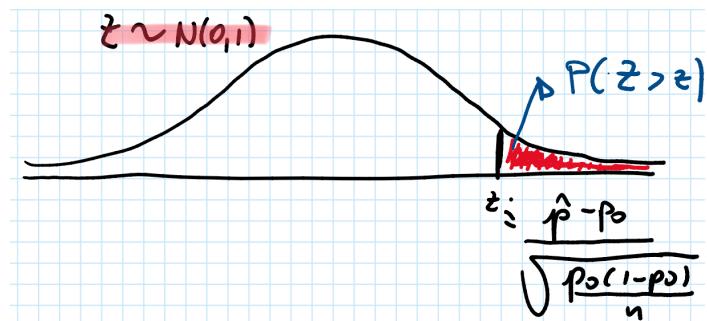
B) Ipotesi alternativa H_A

È l'intervallo di valori che il parametro assume quando l'ipotesi nulla è FALSA.

Come stabilire se rifiutare o no H_0 ?

Statistica di test z

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$



P(Z>z) = p-value (Z=normale standard; z=statistica di test)

$\alpha \in (0,1)$ = livello di significatività

(In generale $0.01 < \alpha < 0.1 \rightarrow$ tra l'1% e il 10%)

Quindi:

SE	ALLORA
<u>p-value $\leq \alpha$</u>	Rifiutiamo H_0
<u>p-value $> \alpha$</u>	Non rifiutiamo H_0

Test di ipotesi sulla proporzione p di successi in una popolazione Bernoulliana

- Popolazione bernoulliana con $p \in (0,1)$
- Fissiamo un valore di confronto p_0 e un livello di significatività α
- Estraiamo un campione in modo che $n * p_0 > 5$ e $n * (1-p_0) > 5$
- Calcoliamo la proporzione campionaria $\hat{p} = \text{num di successi} / n$
- Calcoliamo statistica di test $z = (\hat{p} - p_0) / \sqrt{[p_0(1-p_0)/n]}$

Test ad una coda a destra	Test a due code	Test ad una coda a sinistra
$H_0: p=p_0 ; H_A: p>p_0$	$H_0: p=p_0 ; H_A: p\neq p_0$	$H_0: p=p_0 ; H_A: p<p_0$
$p\text{-value} = P(Z>z)$	$p\text{-value} = 2P(Z> z)$	$p\text{-value} = P(Z<z)$

`prop.test(x,n,p=p0,alternative="greater");`
`prop.test(x,n,p=p0,alternative="two.sided");`
`prop.test(x,n,p=p0,alternative="less").`

Statistica di test per la costruzione di processi decisionali

Tipologia di test	Statistica di test	Distribuzioni delle statistiche di test
Test sulla popolazione $H_0: p=p_0$	$z = (\hat{p} - p_0) / \sqrt{[(p_0(1-p_0)/n)]}$	$N(0,1)$
Test sulla media $H_0: \mu=\mu_0$	a) $z = (x_{\bar{}} - \mu_0) / (\sigma / \sqrt{n})$ b) $T = (x_{\bar{}} - \mu_0) / (s / \sqrt{n})$	a) $N(0,1)$ b) $t_{(n-1)}$
Test sulla deviazione standard $H_0: \sigma=\sigma_0$	$\chi^2 = [(n-1) * S^2] / \sigma_0^2$	χ^2 con $n-1$ gradi di libertà

Test di ipotesi per media e varianza

Test per la media con varianza NOTA

- Popolazione con media μ incognita e σ^2 nota
- Fissiamo $H_0: \mu=\mu_0$
- Fissiamo $\alpha (0, 1)$
- Estraiamo campione con ampiezza n
- Calcoliamo media campionaria $\bar{x} = \text{mean}(x)$
- Costruiamo $z = (\bar{x}-\mu_0) / (\sigma/\sqrt{n})$

Test ad una coda a destra	Test a due code	Test ad una coda a sinistra
$H_0: \mu=\mu_0 ; H_A: \mu>\mu_0$	$H_0: \mu=\mu_0 ; H_A: \mu \neq \mu_0$	$H_0: \mu=\mu_0 ; H_A: \mu<\mu_0$
$p\text{-value} = P(Z>z)$	$p\text{-value} = 2P(Z> z)$	$p\text{-value} = P(Z<z)$

$p\text{-value}<-pnorm(z)$; $p\text{-value}<-2*pnorm(z)$; $p\text{-value}<-1-pnorm(z)$.

`prop.test(x,n,p=p0,alternative="greater");`

`prop.test(x,n,p=p0,alternative="two.sided");`

`prop.test(x,n,p=p0,alternative="less").`

Test per la media con varianza NON NOTA

(primi 4 punti uguali a prima)

- Calcoliamo media campionaria \bar{x} e varianza campionaria S^2
- Costruiamo $t = (\bar{x}-\mu_0) / (s/\sqrt{n})$

Test ad una coda a destra	Test a due code	Test ad una coda a sinistra
$H_0: \mu=\mu_0 ; H_A: \mu>\mu_0$	$H_0: \mu=\mu_0 ; H_A: \mu \neq \mu_0$	$H_0: \mu=\mu_0 ; H_A: \mu<\mu_0$
$p\text{-value} = P(T>t)$	$p\text{-value} = 2P(T> t)$	$p\text{-value} = P(T<t)$

$p\text{-value}<-pt(t, df=n-1)$; $p\text{-value}<-2*pt(abs(t), df=n-1, lower.tail=FALSE)$;

$p\text{-value}<-1-pt(t, df=n-1)$.

oppure

```
t.test(x,mu=mu0, alternative="greater");
t.test(x,mu=mu0,alternative="two.sided");
t.test(x,mu=mu0,alternative="less")
```

Test per la varianza

- Popolazione normale con σ^2 incognita
- Fissiamo $H_0: \sigma^2 = \sigma_0^2$ e fissiamo $\alpha (0,1)$
- Estraiamo campione con ampiezza n
- Calcoliamo varianza campionaria S^2
- Costruiamo chiquadro = $[(n-1)*S^2] / \sigma_0^2$

Test ad una coda a destra	Test a due code	Test ad una coda a sinistra
$H_A: \sigma > \sigma_0$	$H_A: \sigma \neq \sigma_0$	$H_A: \sigma < \sigma_0$
$p\text{-value} = P(X > \chi^2)$	$p\text{-value} = 2\min[P(X < \chi^2); P(X > \chi^2)]$	$p\text{-value} = P(X < \chi^2)$

p-value<-pchisq(chi, df=n-1, lower.tail=FALSE) ;

p-value<-2*min[pchisq(chi,df=n-1,lower.tail=TRUE), pchisq(chi,df=n-1,lower.tail=FALSE)]

p-value<-pchisq(chi,df=n-1,lower.tail=TRUE)

[Test non parametrici: test di wilcoxon per la mediana

- Consideriamo $H_0: \text{mediana}=m$
- Fissiamo $\alpha (0,1)$
- Estraiamo campione casuale

Test ad una coda a destra	Test a due code	Test ad una coda a sinistra
$H_A: \text{mediana}>m$	$H_A: \text{mediana}\neq m$	$H_A: \text{mediana}<m$
<i>wilcox.test(x, mu=m, alternative="greater")</i>	<i>wilcox.test(x, mu=m, alternative="two.sided")</i>	<i>wilcox.test(x, mu=m, alternative="less")</i>

Il test non accetta TIES, ovvero ripetizioni nel vettore di dati.

Si aggiunge “exact=FALSE”, ovvero R non calcola il p-value preciso, ma lo stima in modo che possa funzionare lo stesso.]

Confronto tra parametri (media, dev.standard etc) tra due popolazioni diverse

Test sul confronto tra due popolazioni bernoulliane

- Abbiamo popolazione 1 con proporzione p_1 di successo e
popolazione 2 con proporzione p_2 di successo
- Ampiezza dei campioni n_1 e n_2 , non per forza uguali
- Estraiamo campioni X e Y
- Calcoliamo $\hat{p}_1 = \text{numero successi in } X/n_1$ e
 $\hat{p}_2 = \text{numero successi in } Y/n_2$
- Costruiamo la statistica di test così:
 - $\hat{p} = \text{proporzione totale di successi} = (\hat{p}_1 * n_1 + \hat{p}_2 * n_2) / (n_1 + n_2)$
 - Statistica di test = $z = (\hat{p}_1 - \hat{p}_2) / \sqrt{[\hat{p}(1-\hat{p}) * (1/n_1 + 1/n_2)]}$
Si distribuisce come una normale standard $N(0,1)$

Codifica R:

- Vettore numero di successi **$vp = c(n1 * \hat{p}_1, n2 * \hat{p}_2)$**
- Vettore ampiezze dei campioni **$vn = (n1, n2)$**
- Effettuiamo il prop.test **$prop.test(vp, vn, alternative = "greater, two.sided, less")$**

Test di confronto tra medie, mediane e varianze

Test di confronto tra medie di due popolazioni

- Abbiamo popolazione X e popolazione Y
- Ampiezza dei campioni n_x e n_y , non per forza uguali
- Estraiamo campioni X e Y
- Consideriamo medie e varianze REALI $\mu_x, \mu_y, \sigma^2_x, \sigma^2_y$
- $H_0: \mu_x = \mu_y$
- Calcoliamo \bar{x} , \bar{y} (medie campionarie)
- Calcoliamo S_x^2 e S_y^2 varianze campionarie

Distinguiamo i test sulla base delle informazioni su σ^2_x e σ^2_y

1) Varianze note

Statistica di test: $z = (\bar{x} - \bar{y}) / \sqrt{\sigma^2_x/n_x + \sigma^2_y/n_y}$

Coda a dx: **`p-value<-pnorm(z,lower.tail=FALSE);`**

Due code: **`p-value<-2*pnorm(abs(z), lower.tail=FALSE);`**

Coda a sx: **`p-value<-1-pnorm(z, lower.tail=TRUE).`**

2) Varianze NON note ma uguali $\sigma^2_x = \sigma^2_y$

Statistica di test: $t = (\bar{x} - \bar{y}) / \sqrt{1/n_x + 1/n_y}$

Coda a dx: **`t.test<-(x, y, alternative="greater", var.equal=TRUE)`**

Due code: **`t.test(x, y, alternative="two.sided", var.equal=TRUE)`**

Coda a sx: **`t.test(x, y, alternative="less", var.equal=TRUE)`**

3) Varianze NON note e ignote $\sigma^2_x \neq \sigma^2_y$

Statistica di test: $t = (\bar{x} - \bar{y}) / \sqrt{\frac{S_x^2}{n_x} + \frac{S_y^2}{n_y}}$

Coda a dx: **`t.test<-(x, y, alternative="greater", var.equal=FALSE)`**

Due code: **`t.test(x, y, alternative="two.sided", var.equal=FALSE)`**

Coda a sx: **`t.test(x, y, alternative="less", var.equal=FALSE)`**

Test di confronto tra mediane di due popolazioni

- H_0 : medianaA = medianaB

Utilizziamo il test di Wilcoxon:

Coda a dx: **wilcox.test<-(x, y, alternative="greater")**

Due code: **wilcox.test(x, y, alternative="two.sided")**

Coda a sx: **wilcox.test(x, y, alternative="less")**

Test di confronto tra varianze

- H_0 : $\sigma_A^2 = \sigma_B^2$
- Calcoliamo varianze campionarie S_A^2 e S_B^2

Statistica di test: $f = S_A^2/S_B^2$ distribuzione di Fisher

【 Distribuzione di Fisher

Codifica R:

- Quantili: `qf(α, n, m)`
- $P(F < f) = pf(α, n, m, lower.tail=TRUE)$
- $P(F > f) = pf(α, n, m, lower.tail=FALSE)$]

Coda a dx: **var.test<-(x, y, alternative="greater")**

Due code: **var.test(x, y, alternative="two.sided")**

Coda a sx: **var.test(x, y, alternative="less")**

Test di indipendenza

Serve per verificare se due variabili sono indipendenti o dipendono l'una dall'altra.

- H_0 : variabili sono indipendenti
- H_A : variabili non indipendenti

Codifica R:

- Calcolare la matrice $x=(25,13; 12,15)$ ***x<-rbind(c(25,13), c(12,15))***
- Eseguiamo il test chiquadro ***chisq.test(x)***

Attenzione: se le frequenze in una casella sono meno di 5 appare un Warning

allora ***chisq.test(x,simulate.p.value=TRUE)***

Test di adattamento ad un modello

Serve per verificare se un modello probabilistico ipotizzato per la popolazione sia o meno compatibile con i dati campionari che abbiamo.

Test chi-quadro di adattamento

- n categorie A1, A2 etc
- Vettore delle proporzioni teoriche di elementi per categoria è
 $pt = p1,p2, \dots pk$ ($p1+p2+\dots+pk=1$)
- Estraiamo campione casuale
- Frequenze per categoria $z=z1,z2,\dots,zk$

Eseguiamo il test: ***chisq.test(z,p=pt)***

Test chi-quadro per le distribuzioni continue non note

Consideriamo popolazione con distribuzione X non nota

Serve per verificare se la popolazione si adatta ad un modello di distribuzione X_0

$$H_0: X=X_0 \text{ e } H_A: X \neq X_0$$

Si usa il **Test di Kolmogorov-Smirnov**: ***ks.test(x, "pchisq"/"pnorm"/"punif", df=n)***

Confronto tra le distribuzioni di due popolazioni

- Abbiamo popolazione X e popolazione Y

Serve per stabilire se le distribuzione delle due popolazioni sono uguali oppure diverse.

$$H_0: X=Y \text{ e } H_A: X \neq Y$$

- Estraiamo i campioni x e y

Eseguiamo il test: **ks.test(x,y)**

Verifica della normalità di una popolazione

- Abbiamo popolazione X

Serve per stabilire se la distribuzione di probabilità della popolazione X è normale

$$H_0: X \text{ ha distribuzione normale; } H_A: X \text{ non ha distribuzione normale}$$

- Estraiamo un campione casuale x

Eseguiamo il **Test di Shapiro-Wilk**: **shapiro.test(x)**

Test ANOVA (Analysis of variance)

È un test di ipotesi sulle medie che utilizza la varianza delle distribuzioni per arrivare al calcolo del p-value.

- Consideriamo n popolazioni indipendenti: $X_1, X_2, \dots X_n$
- Assumiamo che in tutte le popolazioni:
 - Distribuzione normale
 - Varianze tutte uguali (tutte la stessa varianza)

$$H_0: \mu_1 = \mu_2 = \dots = \mu_k ; H_A: \text{almeno una } \neq \text{ dalle altre}$$

- Estraiamo i campioni: x_1, x_2, x_n
- Costruiamo una lista con tutti i campioni: ***I<-list(maggio<-may, ...)***
- Costruiamo il dataframe: ***d<-stack(I)***
- Guardiamo struttura del dataframe: ***str(d)***

Eseguiamo il test: ***oneway.test (values~ind, data=d, var.equal=TRUE)***

Se NON possiamo assumere la normalità della distribuzione?

Test di Kruskall-Wallis

- Consideriamo n popolazioni indipendenti, tutte con la stessa distribuzione (non necessariamente nota)

$$H_0: \mu_1 = \mu_2 = \dots = \mu_k ; H_A: \text{almeno una } \neq \text{ dalle altre}$$

- Eseguiamo le altre operazioni descritte precedentemente

Eseguiamo il test: ***kruskal.test (values~ind, data=d)***